Martine DETE
Amiels Caprills DJONDJIN
Tom Allusse

Projet NovaRetail – RGPD & Sécurité

Analyse des risques

La base customer_transactions contenait des informations sensibles, notamment les adresses emails des clients. Le stockage en clair de ces données pose plusieurs risques :

- Violation de la confidentialité : En cas de fuite ou d'accès non autorisé, les informations personnelles peuvent être exploitées pour du phishing ou du spam.
- Non-conformité RGPD : Le RGPD impose que seules les données strictement nécessaires soient conservées et que leur traitement soit sécurisé. Les emails en clair ne respectaient pas le principe de minimisation des données.
- Gestion des données corrompues : La présence de valeurs NULL dans le champ country peut entraîner des erreurs d'analyse ou de reporting et compliquer la conformité.

Application des principes RGPD dans le pipeline ETL

Notre pipeline ETL Java/Spark respecte plusieurs principes clés du RGPD :

- Minimisation des données : La suppression de la colonne customer_email garantit que seules les informations nécessaires au traitement commercial et statistique sont conservées.
- Exactitude et mise à jour des données : Les transactions avec country = NULL sont filtrées, ce qui assure que seules des données fiables sont stockées.
- Portabilité et suppression des données : Grâce à la partition par pays, il est possible de localiser rapidement les fichiers JSON correspondants à un client et de les supprimer à sa demande.

Cas d'usage : suppression totale des données d'un client espagnol

1. Identifier la partition correspondant au pays « Espagne ».
2. Filtrer les fichiers JSON pour retrouver les transactions du client (via transaction_id).
3. Supprimer ou anonymiser les données ciblées.

Cette approche assure la conformité avec le droit à l'effacement (« droit à l'oubli ») du RGPD.

Sécurité et architecture Big Data

1 - Mesures de protection des fichiers JSON

Pour sécuriser l'export final :

- Permissions d'accès : Restreindre l'accès aux dossiers JSON aux seuls administrateurs ou services autorisés.
- Chiffrement des données : Utiliser un chiffrement AES ou similaire pour protéger les fichiers au repos.
- Sauvegardes sécurisées : Mettre en place des sauvegardes chiffrées et périodiques sur des serveurs sécurisés.
- Journalisation et audit : Enregistrer toutes les opérations de lecture et suppression pour assurer la traçabilité.

2 - Complexité de la sécurité dans le Big Data

- Dans un environnement distribué comme Spark/Hadoop, les données sont stockées sur plusieurs nœuds, ce qui rend le contrôle d'accès plus complexe qu'une base SQL centralisée.
- La gestion des droits doit se faire sur chaque nœud et sur les fichiers distribués, ce qui nécessite des outils supplémentaires.
- Le chiffrement et la partition des données ajoutent une couche de sécurité mais augmentent la complexité opérationnelle.

Conclusion

Le pipeline ETL développé garantit :

- La protection des données personnelles conformément au RGPD.
- La fiabilité des données grâce au nettoyage et au tri.
- La traçabilité et la possibilité de suppression ciblée des données clients.
- Une architecture Big Data sécurisée et optimisée pour le futur Data Lake.